UNIVERSIDADE FEDERAL DE SÃO PAULO

ESCOLA PAULISTA DE POLÍTICA, ECONOMIA E NEGÓCIOS (EPPEN)

HELOÍSA REGINA DOMINGUES PIRES

Relevância do desemprego e da inflação na determinação da inadimplência e perda esperada (PDD) no Brasil no período de 2012 a 2020 para o produto de cartão de crédito

OSASCO

2025

HELOÍSA REGINA DOMINGUES PIRES

Relevância do desemprego e da inflação na determinação da inadimplência e perda esperada (PDD) no Brasil no período de 2012 a 2020 para o produto de cartão de crédito

Trabalho de Conclusão de Curso apresentado à Universidade Federal de São Paulo como requisito parcial para obtenção do título de Bacharel em Ciências Atuariais.

Orientador(a): Ricardo Hirata Ikeda

OSASCO

2025

Na qualidade de titular dos direitos autorais, em consonância com a Lei de direitos autorais nº 9610/98, autorizo a publicação livre e gratuita desse trabalho no Repositório Institucional da UNIFESP ou em outro meio eletrônico da instituição, sem qualquer ressarcimento dos direitos autorais para leitura, impressão e/ou download em meio eletrônico para fins de divulgação intelectual, desde que citada a fonte.

Autorizo a reprodução e divulgação total ou parcial deste trabalho, por qualquer meio convencional ou eletrônico, para fins de estudo e pesquisa, desde que citada a fonte.

Ficha catalográfica elaborada pela Biblioteca Unifesp Osasco, CRB-8: 3998, e Departamento de Tecnologia da Informação Unifesp Osasco, com os dados fornecidos pelo(a) autor(a)

P667r PIRES, Heloísa Regina Domingues

Relevância do desemprego e da inflação na determinação da inadimplência e perda esperada (PDD) no Brasil no período de 2012 a 2020 para o produto de cartão de crédito / Heloísa Regina Domingues Pires. - 2025.

52 f. :il.

Trabalho de conclusão de curso (Ciências Atuariais) - Universidade Federal de São Paulo - Escola Paulista de Política, Economia e Negócios, Osasco, 2025.

Orientador: Ricardo Hirata Ikeda.

1. Inadimplência. 2. Risco de crédito. 3. PDD. 4. Inflação. 5. Desemprego. I. Ikeda, Ricardo Hirata, II. TCC - Unifesp/EPPEN. III. Título.

CDD: 368

Relevância do desemprego e da inflação na determinação da inadimplência e perda esperada (PDD) no Brasil no período de 2012 a 2020 para o produto de cartão de crédito

Trabalho de Conclusão de Curso apresentado à Universidade Federal de São Paulo como requisito parcial para obtenção do título de bacharel em Ciências Atuariais.

Aprovado em: 12 de dezembro de 2025

Prof. Dr. Orientador Ricardo Hirata Ikeda
Universidade Federal de São Paulo

Prof. Dr. Amaury de Souza Amaral

Instituição: PUC - SP

Prof(a). Dr(a). Heloisa Candia Hollnagel
Instituição Universidade Federal de São Paulo

AGRADECIMENTOS

Agradeço à minha mãe e pai, meus avós, tio e irmã, professores e colegas de turma.

Dedico este trabalho aos meus pais e avós, pelo estímulo, carinho e compreensão.

RESUMO

Este trabalho investiga a relevância de variáveis macroeconômicas — especificamente desemprego e inflação — na determinação da inadimplência e, consequentemente, da Perda Esperada (PDD) no segmento de cartão de crédito no Brasil, no período de 2012 a 2020. A partir de séries temporais mensais obtidas de fontes oficiais, são aplicados modelos ARIMA e ARIMAX segundo a metodologia Box-Jenkins, com o objetivo de avaliar se indicadores econômicos externos contribuem para melhorar a previsão da inadimplência em relação a modelos baseados apenas no comportamento histórico da própria série.

Os resultados apontam que a inclusão das variáveis exógenas aumenta a capacidade explicativa do modelo, indicando que choques macroeconômicos influenciam de forma significativa o risco de crédito. A inflação e o desemprego demonstraram associação estatisticamente relevante com a inadimplência, reforçando a importância de que instituições financeiras incorporem fatores econômicos sistêmicos em seus modelos de risco. Conclui-se que a integração de variáveis macroeconômicas pode aprimorar a acurácia das projeções de PDD e fornecer suporte para decisões mais robustas de concessão, monitoramento e gestão de carteiras de crédito.

Palavras-chave: inadimplência; risco de crédito; PDD; inflação; desemprego; ARIMA; ARIMAX.

ABSTRACT

This study investigates the relevance of macroeconomic variables — specifically unemployment and inflation — in determining default rates and, consequently, Expected Loan Losses in the credit card segment in Brazil, from 2012 to 2020. Using monthly time series obtained from official sources, ARIMA and ARIMAX models are applied according to the Box-Jenkins methodology, with the aim of evaluating whether external economic indicators contribute to improving default rate forecasting compared to models based solely on the historical behavior of the series itself. The results indicate that the inclusion of exogenous variables increases the explanatory power of the model, suggesting that macroeconomic shocks significantly influence credit risk. Inflation and unemployment showed a statistically significant association with default rates, reinforcing the importance of financial institutions incorporating systemic economic factors into their risk models. It is concluded that the integration of macroeconomic variables can improve the accuracy of loan loss provisions projections and provide support for more robust decisions regarding the granting, monitoring, and management of credit portfolios.
Keywords: default; credit risk; inflation; unemployment; ARIMA; ARIMAX.

SUMÁRIO

1. **Introdução** 10

1.1. Situação Problema 10

1.2. Objetivo 11

1.3. Justificativa 11

1.4. Metodologia 12

1.5. Hipóteses 12

2. Indicadores Macroeconômicos 6

2.1. Inadimplência e Inflação 6

2.2 Risco de Crédito: Componentes Endógenos e Exógenos no Contexto do Cartão de Crédito 8

2.3 Cartão de Crédito e Rolagens de Atraso 17

3. Breve tópico sobre a Basileia 10

3.1 O Acordo da Basiléia 10

3.2 Modelos de Medição de Risco de Crédito 13

3.3 Ações Decorrentes do Acordo da Basiléia 23

4. Modelo ARIMA 16

4.1 Considerações do modelo utilizado 16

4.2 Coleta de dados e seleção da amostra 26

4.3 Tratamento de dados 28

4.4 Apresentação e análise dos resultados 33

5. Considerações finais 37

Referências 39

Apêndice 42

Relevância do desemprego e da inflação na determinação da inadimplência e perda esperada (PDD) no Brasil no período de 2012 a 2020 para o produto de cartão de crédito

1. Introdução

Nos últimos anos, o uso do cartão de crédito tornou-se uma prática comum para grande parte da população brasileira, principalmente alavancado por programas de pontos das bandeiras em geral. Essa facilidade de pagamento trouxe muitos benefícios, como comodidade e possibilidade de parcelamento, mas também ocasionou um aumento considerável na inadimplência.

A inadimplência acontece quando o consumidor não consegue cumprir com os pagamentos acordados, o que pode gerar impactos negativos para o sistema financeiro e para a vida pessoal do usuário. Diante desse cenário, entender os fatores que levam à inadimplência de cartão de crédito é essencial para que instituições financeiras prevejam o comportamento dos consumidores e possam agir de forma preventiva.

Com o crescimento do crédito concedido e a volatilidade do panorama econômico, torna-se ainda mais relevante compreender os elementos que influenciam a insolvência deste produto.

1.1. Situação Problema

A literatura sobre risco de crédito tem buscado aprimorar os modelos preditivos tradicionais como regressões logísticas, séries temporais e modelos de *score* por meio da inclusão de variáveis macro e microeconômicas, entre elas o desemprego e a inflação, como fatores explicativos adicionais do comportamento da inadimplência.

Neste contexto, o presente estudo propõe avaliar em que medida a incorporação dessas variáveis em modelos de previsão de risco de crédito, aplicados ao produto cartão de crédito, contribui para melhorar a capacidade de estimar a **Perda Esperada (PDD)**.

Assim, busca-se responder à seguinte questão de pesquisa:

A inclusão destas variáveis, utilizando a metodologia ARIMA, contribui significativamente para a previsão de risco de crédito bancário referente ao produto de cartão de crédito e suas composições na PDD?

A inflação e desemprego melhoram a acurácia dos modelos preditivos de risco de crédito bancário de cartão de crédito?

1.2. Objetivo

O aumento dos índices de atraso nos pagamentos compromete a saúde financeira dos bancos e eleva os custos operacionais, além de prejudicar o crédito disponível para os consumidores.

Dessa forma, este trabalho tem como objetivo analisar a relevância das variáveis desemprego e inflação na determinação da inadimplência e da PDD no Brasil, considerando a dinâmica macroeconômica do período estudado, visto que identificar os fatores que levam ao atraso no pagamento é essencial para desenvolver estratégias eficazes de prevenção e controle.

Objetivo específico:

- Avaliar a relevância das variáveis desemprego e inflação na estimação da inadimplência no Brasil

1.3. Justificativa

O nível de inadimplência afeta tanto a sustentabilidade das instituições quanto o bem-estar financeiro dos consumidores. Em especial, em momentos de instabilidade econômica, como os enfrentados pelo Brasil nos últimos anos, torna-se essencial a adoção de ferramentas que permitam a antecipação de comportamentos de risco e o aprimoramento dos mecanismos de prevenção.

Apesar de pouco divulgado pelas instituições financeiras seus modelos de previsão, seja por razão estratégica ou pela não utilização de fato, é visível sua preocupação no monitoramento do comportamento das variáveis macroeconômicas no seu cotidiano. Todavia, esse estudo busca avaliar eventual ganho de eficiência na gestão do risco de

crédito baseado no comportamento do desemprego e da inflação no período de 2012 a 2020.

Este trabalho busca contribuir para a literatura acadêmica e para a prática profissional ao propor uma abordagem que alia rigor estatístico, aplicabilidade prática e aderência à realidade brasileira. A implementação de modelos mais refinados pode oferecer às instituições financeiras melhores parâmetros para decisões de concessão, gestão e recuperação de crédito, impactando positivamente a estabilidade do sistema financeiro como um todo.

1.4. Metodologia

Este trabalho terá suas análises baseadas na utilização das metodologias bibliográfica, descritiva e empírico-analítica, conforme a descrição de Lakatos e Marconi (2003), dado que a partir de evidências teóricas, mesmo que exploratórias, as descrevendo de forma ordenada, serão estruturadas análises de dados reais para atingir o objetivo deste estudo.

1.5. Hipóteses

Este trabalho parte do pressuposto de que a projeção da Perda Esperada (PDD) tem a inadimplência de cartão de crédito com a sua proxy natural, já que quanto maior o nível de inadimplência dos agentes econômicos, maior o volume de PDD demandada para que se sustente a saúde financeira das instituições.

A utilização dessas variáveis visa fornecer uma base para estimativa mais robusta e contextualizada da inadimplência, contribuindo para o aprimoramento dos processos de gestão de risco de crédito nas instituições financeiras.

Com base na literatura de risco de crédito e na relação entre condições macroeconômicas e capacidade de pagamento das famílias, este estudo formula hipóteses testáveis a respeito do efeito do desemprego e da inflação sobre a inadimplência no produto de cartão de crédito no Brasil.

H1 (Desemprego → inadimplência): variações positivas na taxa de desemprego estão associadas a variações positivas na inadimplência de cartão de crédito, isto é, espera-

se **coeficiente positivo** para a variável desemprego no modelo ARIMAX (**β_desemprego > 0**). O racional é que o aumento do desemprego reduz a renda e eleva a probabilidade de atraso e default, deteriorando a capacidade de pagamento dos consumidores.

H2 (Inflação → inadimplência): variações positivas na inflação (IPCA) estão associadas a variações positivas na inadimplência de cartão de crédito, isto é, espera-se **coeficiente positivo** para a variável IPCA no modelo ARIMAX (**β_ipca > 0**). O mecanismo esperado ocorre porque a inflação corrói o poder de compra e reduz a renda real disponível, pressionando o orçamento das famílias e aumentando a probabilidade de atraso no pagamento.

Dessa forma, as hipóteses serão testadas empiricamente por meio da significância estatística e do sinal dos coeficientes estimados das variáveis exógenas no modelo ARIMAX, avaliando-se se a inclusão de desemprego e inflação contribui para explicar variações adicionais na inadimplência além de sua dinâmica autorregressiva.

1.6. Fundamentação teórica

A análise de variáveis macroeconômicas é essencial para a compreensão do comportamento da inadimplência no sistema financeiro. O não pagamento do saldo devedor de pessoas físicas é fortemente influenciado por variáveis como o Índice de Preços ao Consumidor Amplo (IPCA), a taxa básica de juros (SELIC) e o Produto Interno Bruto (PIB), conforme apontam estudos recentes (MARÇAL, 2020).

Entre os principais indicadores explorados no estudo, destacam-se a inflação e o desemprego, ambos diretamente relacionados à capacidade de pagamento dos consumidores, e pilares sensíveis em momentos de instabilidade macroeconômica, como mostram as leituras recentes de inflação e mercado de trabalho no Brasil (IPEA, 2025; IMF, 2025; Ministério da Fazenda, 2025).

A pesquisa de Marçal (2020), que analisou dados do cenário brasileiro entre maio de 2021 e dezembro de 2024, concluiu que a inadimplência é **positivamente correlacionada com o PIB e a taxa de juros**, e **negativamente com a inflação**. Isso indica que, em momentos de crescimento econômico e juros elevados, há maior propensão ao aumento da inadimplência, caracterizando-a como um fenômeno pró-cíclico.

Todas essas variáveis ajudam a entender e a precificar corretamente a **PDD**: ela representa o valor que a instituição financeira estima que não conseguirá recuperar de seus créditos concedidos — como empréstimos, financiamentos ou cartões de crédito — devido à inadimplência dos clientes.

2. Indicadores Macroeconômicos

2.1. Inadimplência e Inflação

A inflação corresponde a um aumento do nível geral dos preços (Samuelson & Nordhaus, 2005), o que resulta na redução do poder de compra da moeda e na corrosão da renda disponível dos consumidores. Esse fenômeno implica que, com o mesmo salário, as famílias conseguem adquirir uma quantidade menor de bens e serviços, impactando diretamente sua capacidade de honrar compromissos financeiros. Segundo Mankiw (2019), quando a inflação se acelera, há redistribuição de renda entre credores e devedores, uma vez que o valor real das dívidas se altera.

Além disso, de acordo com o Banco Central do Brasil (2023), períodos de inflação elevada tendem a pressionar as taxas de juros básicas (SELIC), aumentando o custo do crédito e contribuindo para maiores índices de inadimplência, em especial em produtos como o cartão de crédito. Assim, compreender a dinâmica da inflação é essencial para avaliar o risco de crédito, pois ela funciona como um elo direto entre as condições macroeconômicas e o comportamento financeiro das famílias.

Esse indicador é medido principalmente pelo Índice Nacional de Preços ao Consumidor Amplo (IPCA), Índice de Preços no Consumidor (IPC) e o Deflator do Produto Interno Bruto (PIB), impacta o poder de compra da população, corroendo a renda disponível e, consequentemente, comprometendo a capacidade de honrar dívidas. Segundo o Banco Central do Brasil (2023), períodos de inflação elevada tendem a refletir em maior inadimplência no crédito rotativo, como o cartão de crédito.

A inflação é composta por dois subtipos:

A inflação de demanda ocorre quando existe um excesso de procura em relação à oferta disponível. Dentre os fatores que podem causar esse tipo de inflação, quatro merecem destaque:

- Aumento da renda disponível, que ocorre pelos aumentos reais dos salários, efeito riqueza ou uma redução da carga tributária, assim como, por meio de políticas de transferência de renda;
- Expansão dos gastos públicos, os quais elevam o nível de demanda agregada;
- Expansão do crédito e redução das taxas de juros, ambos os fatores influenciam na demanda de consumo e investimentos;
- Expectativa dos agentes econômicos, que possui a capacidade de interferir no nível de demanda da economia. (LANZANA, A. E. T. Economia brasileira: fundamentos e atualidade. 5a.. ed. São Paulo: Atlas, 2017.)

E a inflação de custos, que decorre de pressões geradas nos custos e consequentemente repassadas aos preços. Este tipo de inflação, também recebe a denominação de choque de oferta, que pode acontecer mesmo quando a demanda permanece estável, onde são alteradas somente as despesas por parte do produtor. Dentre os inúmeros fatores que podem levar a esse tipo de inflação, podem ser destacados quatro:

- Elevação da taxa de juros, que acaba por aumentar os custos da produção;
- Uma desvalorização cambial, que acaba gerando uma inflação nos produtos que são importados, os preços externos aumentam relativamente, em especial commodities e insumos;
- O custo da mão de obra, onde a inflação pode vir atrelada ao aumento do salário nominal;
- Aumento de impostos, que pressiona a elevação dos serviços e produtos (LANZANA, 2017).

Já o desemprego é um dos principais fatores que afetam a inadimplência. De acordo com estudos realizados pelo IPEA em 2022, a relação de taxa de desemprego e inadimplência é estatisticamente significativa, indicando que, quando a pessoa perde sua fonte de renda, perde-se drasticamente a capacidade de pagamento e compra dos consumidores.

Ambas as variáveis impõem desafios à modelagem do risco de crédito, exigindo

técnicas estatísticas robustas que incorporem tais influências sistêmicas na precificação e concessão de crédito, e para o cálculo de PDD.

No contexto brasileiro, esses indicadores têm se mostrado particularmente sensíveis às oscilações econômicas, especialmente em períodos de crise, como o desencadeado pela pandemia da COVID-19 entre 2020 e 2023.

2.2 Risco de Crédito: Componentes Endógenos e Exógenos no Contexto do Cartão de Crédito

O risco de crédito pode ser compreendido como resultado da interação entre fatores endógenos à instituição financeira — relacionados às políticas internas de concessão, gestão e cobrança — e fatores exógenos, associados ao ambiente macroeconômico, como inflação, desemprego e taxa de juros, conforme amplamente discutido na literatura de risco de crédito e nos acordos de Basileia (Altman, 1968; Saunders & Allen, 2002; BCBS, 2004).

Os componentes endógenos referem-se às políticas internas, como critérios de concessão, estratégias de cobrança e perfil de portfólio. Já os exógenos dizem respeito a elementos do ambiente macroeconômico, como inflação, desemprego, taxas de juros e estabilidade política.

No caso específico do cartão de crédito, o risco apresenta particularidades: por ser uma linha de crédito rotativo e de fácil acesso, tende a atrair consumidores com maior propensão ao endividamento. De acordo com dados da Serasa Experian (2023), o cartão de crédito representa uma das principais fontes de inadimplência entre os brasileiros.

Modelos de risco que ignoram os fatores exógenos tendem a subestimar a variabilidade do comportamento do consumidor, principalmente em ciclos econômicos recessivos. Assim, torna-se essencial a integração de indicadores macroeconômicos à modelagem interna para maior robustez preditiva (SILVA; MATTOS, 2021).

2.3 Cartão de Crédito e Rolagens de Atraso

A rolagem de atraso no cartão de crédito ocorre quando o consumidor não quita o valor total da fatura e opta pelo pagamento mínimo ou pelo parcelamento. Esse

comportamento leva ao acúmulo de juros elevados e ao aumento da dívida ao longo do tempo.

De acordo com estudos do Banco Central (2023), consumidores que realizam o pagamento mínimo por três meses consecutivos possuem risco 4 vezes maior de inadimplência futura, o que impacta diretamente o objeto de estudo deste trabalho: o cálculo da PDD. As rolagens sucessivas, portanto, são um indicador de deterioração do perfil de crédito.

Em ambientes de instabilidade econômica, como aumento do desemprego e da inflação, a frequência das rolagens tende a se intensificar, tornando-se um sinal importante para o monitoramento preditivo de risco. Ferramentas baseadas em aprendizado de máquina vêm sendo adotadas por instituições financeiras para antecipar esse tipo de comportamento e implementar estratégias de mitigação mais eficientes (COSTA; ALMEIDA, 2020).

3. Breve tópico sobre a Basileia

3.1 O Acordo da Basiléia

De acordo com o documento *International Convergence of Capital Measurement and Capital Standards*, o Acordo da Basiléia surgiu como resposta à necessidade de estabelecer padrões internacionais a bancos que tinham operações em mais de um país, de forma a fortalecer a resiliência do sistema financeiro global (BCBS, 1988).

Proposto inicialmente em 1988 pelo Comitê de Supervisão Bancária da Basiléia (BCBS), o marco regulatório buscava uniformizar práticas de capital mínimo e mensuração de risco, reduzindo a probabilidade de crises sistêmicas provocadas por inadimplência em larga escala.

O acordo define os detalhes da estrutura acordada para mensurar a adequação de capital e o padrão mínimo a ser alcançado, que as autoridades nacionais de supervisão representadas no comitê propuseram para adoção em seus respectivos países. Esta estrutura e o padrão nela contido foram endossados pelos presidentes dos Bancos Centrais e chefes de Supervisão Bancária dos países do G10 (BCBS, 1988).

Atualmente, o acordo da Basiléia se encontra em sua terceira versão, que quando comparada às publicações anteriores, apresenta as reformas do Comitê de Basiléia 1 para fortalecer as regras globais de capital e liquidez com o objetivo de promover um setor bancário mais resiliente (BCBS, 2010).

De acordo com o *Basel Committee on Banking Supervision,* o objetivo das reformas é melhorar a capacidade do setor bancário de absorver choques decorrentes do estresse financeiro e econômico, qualquer que seja a fonte, reduzindo assim o risco de contágio do setor financeiro para a economia real. O acordo da Basileia III surge num cenário logo após a crise financeira de 2008, e ampliou o escopo regulatório, incluindo métricas de liquidez e alavancagem. Foram criados instrumentos como o Índice de Cobertura de Liquidez (LCR) e o Índice de Estabilidade de Liquidez de Longo Prazo (NSFR), bem como colchões de capital anticíclicos (BCBS, 2010; REPULLO; SUAREZ, 2013).

Nesse contexto, a Perda Esperada (PDD) assume papel central, pois reflete diretamente as exigências prudenciais do Acordo da Basiléia, servindo como parâmetro para absorção de perdas decorrentes da inadimplência. Assim, a articulação entre Basileia e variáveis macroeconômicas, como desemprego e inflação, evidencia a necessidade de modelos capazes de antecipar choques sistêmicos, ajustando provisões de forma a preservar a solidez do sistema financeiro como um todo.

No Brasil, a adoção dos Acordos da Basiléia é conduzida pelo Banco Central do Brasil (BCB), que adapta as diretrizes internacionais do Comitê de Basileia às especificidades do sistema financeiro nacional. A implementação tem ocorrido de maneira gradual, por meio de resoluções do Conselho Monetário Nacional (CMN) e circulares do BCB, assegurando compatibilidade com a realidade local sem comprometer a convergência com os padrões globais (BANCO CENTRAL DO BRASIL, 2013).

- Basileia I (1988): Introduzido no Brasil na década de 1990, com foco no requerimento de capital mínimo de 8% dos ativos ponderados pelo risco. O objetivo foi fortalecer a solvência das instituições em um período marcado por instabilidade inflacionária e reformas estruturais (BCBS, 1988).
- Basileia II (2004): Incorporado a partir de 2007 no Brasil, por meio da Resolução CMN nº 3.490/2007, que estabeleceu critérios mais sofisticados para mensuração de riscos de crédito, mercado e, principalmente, o **risco operacional**. Foram introduzidos tanto o modelo padronizado quanto a possibilidade de utilização de modelos internos (Internal Ratings-Based – IRB) (BCBS, 2004).

Apesar dos avanços, a literatura mostra que os acordos de Basileia, em especial o Basileia II, apresentam efeitos pró-cíclicos, amplificando crises ao restringir crédito em períodos de recessão. Repullo e Suárez (2009) demonstram, em um modelo de equilíbrio dinâmico, que os requerimentos de capital baseados em risco podem levar a uma redução média de 11% na oferta de crédito quando a economia entra em recessão, mesmo quando os bancos mantêm colchões de capital preventivos. Com isso, uma nova reforma no acordo se fez necessária, principalmente após a crise de 2008.

- Basileia III (2010): dessa maneira, esse novo acordo surgiu buscando mitigar a pró-ciclicidade identificada na Basileia II, onde foram incorporados mecanismos anticíclicos que obrigam os bancos a constituírem capital adicional em fases de expansão de crédito e liberando-o em momentos de retenção. Sua implementação no Brasil iniciou-se em 2013, com adaptação progressiva das regras internacionais. A Resolução CMN nº 4.193/2013 e normativos subsequentes definiram a estrutura de capital, incluindo a segregação entre capital de Nível I e Nível II, a exigência de capital principal e a criação de colchões de capital. O principal risco abarcado por essa normativa foi o risco de crédito. (capital conservation buffer de capital anticíclico) (BANCO CENTRAL DO BRASIL, 2013).

Além disso, foram introduzidos índices de liquidez, como o Índice de Cobertura de Liquidez (LCR) e o Índice de Estabilidade de Liquidez de Longo Prazo (NSFR), aplicados conforme cronograma estabelecido pelo BCB.

O Banco Central adota um modelo prudencial robusto, frequentemente mais conservador que o mínimo recomendado pelo Comitê de Basileia (*Relatório de Estabilidade Financeira, 2022)*. Esse alinhamento busca prevenir efeitos pró-cíclicos e reduzir a vulnerabilidade do sistema financeiro frente a choques macroeconômicos, como os derivados de desemprego elevado e inflação persistente (IPEA, 2022).

Na prática, a aplicação da Basiléia no Brasil impacta diretamente a Perda Esperada (PDD), já que as instituições financeiras devem manter provisões compatíveis com a exposição ao risco de crédito. Isso cria incentivos para o desenvolvimento de modelos internos mais robustos, capazes de incorporar variáveis macroeconômicas e antecipar deteriorações de carteira (COSTA; ALMEIDA, 2020).

Apesar dos avanços, críticas recaem sobre a **pró-ciclicidade** das regras de capital, que podem amplificar crises ao restringir crédito em períodos recessivos (REPULLO; SUAREZ, 2013). Além disso, países emergentes enfrentam dificuldades na implementação, dado que os requisitos podem restringir a expansão do crédito e não consideram plenamente especificidades locais (ALLEN; CARLETTI; MARQUEZ, 2011).

Medidas como a exigência de capital mínimo pode reduzir a oferta de crédito em períodos de desaceleração econômica, e em emergentes, onde o crédito é motor do crescimento, esse efeito é ainda mais danoso.

3.2 Modelos de Medição de Risco de Crédito

Os acordos da Basileia estimularam o desenvolvimento e a adoção de modelos quantitativos de mensuração de risco de crédito, tanto por meio de metodologias padronizadas quanto por abordagens internas (IRB – Internal Ratings-Based). No caso brasileiro, a avaliação da inadimplência e da PDD é realizada a partir de séries históricas e critérios de provisionamento estabelecidos pelo Banco Central, mas cresce a importância do uso de técnicas estatísticas mais sofisticadas.

Entre os principais modelos de medição de risco, destacam-se:

- **Modelos Estatísticos Tradicionais:** como regressão logística, análise discriminante e séries temporais (ARIMA e suas extensões). Eles permitem avaliar o impacto de variáveis explicativas — no caso deste estudo, desemprego e inflação — sobre a inadimplência (Altman, 1968; JACKSON; PERA, 1999).
- **Modelos Baseados em Probabilidade de Default (PD)**: estimam a chance de inadimplência de determinado contrato ou portfólio, muitas vezes incorporando variáveis macroeconômicas como o credit metrics.
- **Foundation IRB e Advanced IRB (IRB):** aplicados sob supervisão regulatória, permitem capturar a heterogeneidade dos portfólios (BCBS, 2004). Além disso, permitem que as instituições financeiras utilizem estimativas próprias de PD, LGD (perda em caso de inadimplência) e EAD (exposição no momento da inadimplência), sujeitas à validação regulatória.
- **Modelos de Machine Learning**: recentemente, técnicas como random forests, gradient boosting e redes neurais têm sido aplicadas para identificar padrões não lineares no comportamento de inadimplência.

No presente trabalho, opta-se pela utilização da modelagem *ARIMA* e *ARIMAX*, justamente por sua capacidade de capturar efeitos dinâmicos de séries temporais e integrar

variáveis macroeconômicas. Tal escolha encontra respaldo na literatura, que indica que modelos univariados, quando expandidos para incorporar choques exógenos, apresentam maior robustez em cenários de instabilidade econômica.

3.3 Ações Decorrentes do Acordo da Basiléia

As exigências da Basileia implicam uma série de ações estratégicas e operacionais para instituições financeiras, dentre as quais se destacam:

- Gestão Prudencial de Capital: necessidade de manter níveis de capital compatíveis com a exposição ao risco, ajustando o volume de crédito concedido às condições de solvência.
- Aprimoramento da Modelagem de Risco: incentivo à adoção de técnicas quantitativas mais sofisticadas, que considerem não apenas o histórico de inadimplência, mas também fatores macroeconômicos e comportamentais.
- Monitoramento Contínuo: obrigatoriedade de relatórios periódicos de risco, em consonância com as práticas de supervisão bancária.
- Disciplina de Mercado: fortalecimento da transparência, exigindo divulgação de informações sobre riscos, provisões e indicadores de capital.
- Gestão Anticíclica: constituição de colchões de capital e provisões que atuem de forma contracíclica, de modo a absorver perdas potenciais em momentos de crise econômica.

Essas ações demonstram que o Acordo da Basileia transcende a mera exigência de capital mínimo, funcionando como instrumento normativo e indutor de boas práticas de governança e gestão de risco. Para o caso brasileiro, marcado por oscilações de desemprego e inflação, torna-se ainda mais relevante integrar os princípios da Basileia a modelos que capturem adequadamente os impactos de tais variáveis sobre a inadimplência de cartões de crédito e, consequentemente, sobre a PDD.

Apesar dos avanços, a literatura mostra que os acordos de Basileia, em especial o Basileia II, apresentam efeitos pró-cíclicos, amplificando crises ao restringir crédito em períodos de recessão. Repullo e Suárez (2009) demonstram, em um modelo de equilíbrio

dinâmico, que os requerimentos de capital baseados em risco podem levar a uma redução média de 11% na oferta de crédito quando a economia entra em recessão, mesmo quando os bancos mantêm colchões de capital preventivos.

O estudo de Repullo e Suárez (2009) também sugere alternativas regulatórias para mitigar esses efeitos, como ajustes contracíclicos nos parâmetros de risco do Basileia II. Essa perspectiva se aproxima das medidas adotadas no Basileia III, que introduziu colchões de capital anticíclicos e buscou reduzir a vulnerabilidade dos sistemas financeiros a choques macroeconômicos.

4. Modelo ARIMA

4.1 Considerações do modelo utilizado

Segundo Morettin e Toloi (2006), o estudo de séries temporais busca investigar o mecanismo gerador dos dados, descrever seu comportamento, identificar periodicidades e realizar previsões. Os autores destacam que um pressuposto central para a aplicação dos modelos de séries temporais é a estacionariedade, ou seja, a constância das propriedades estatísticas da série ao longo do tempo, refletindo um equilíbrio estável.

O modelo ARIMA (*AutoRegressive Integrated Moving Average* - modelos autorregressivos integrados de médias móveis), proposto originalmente por Box e Jenkins (1970), constitui uma das abordagens mais consolidadas para a análise e previsão de séries temporais. Sua estrutura permite capturar padrões autorregressivos e de médias móveis, possibilitando previsões a partir do comportamento histórico da variável analisada. Essa metodologia tornou-se referência clássica para a modelagem de processos estocásticos estacionários e não estacionários.

Quando a série apresenta tendências ou variações sazonais, é necessário aplicar transformações — como diferenciação ou ajustes de tendência — para torná-la estacionária antes da estimação do modelo. Tal procedimento garante que as leis de probabilidade que regem o processo não se alterem com o tempo, condição essencial para a validade dos modelos ARIMA (MORETTIN; TOLOI, 2006).

A partir dessa base conceitual, para capturar o efeito de fatores econômicos externos, será utilizada a extensão ARIMAX (uma extensão do ARIMA que incorpora variáveis exógenas), permitindo avaliar de forma mais abrangente a influência de fatores macroeconômicos sobre a inadimplência e a Perda Esperada (PDD), sendo especialmente adequado para prever variáveis econômicas que apresentam comportamento cíclico e autocorrelação significativa.

A modelagem ARIMA seguirá os passos propostos na metodologia de Box-Jenkins:

Definição formal do ARIMA(p,d,q): $\phi(B)(1-B)^d Y_t = \theta(B)\varepsilon_t$

Identificação do modelo, com análise visual da série, tratamento dos dados e aplicação do teste Dickey-Fuller Aumentado (ADF).

Estimação dos parâmetros (p, d, q) por meio de critérios como AIC e BIC, selecionando o modelo que melhor se ajusta aos dados.

Diagnóstico do modelo, analisando os resíduos (erro) para verificar se seguem um comportamento branco (sem padrão), por meio de testes como Ljung-Box.

As variáveis de inflação e taxa de desocupação serão inseridas como auxiliares no modelo. Essa abordagem permite verificar se tais variáveis explicam variações adicionais na série da PDD além do comportamento inerente da própria série.

A avaliação da significância estatística das variáveis exógenas será feita por meio dos coeficientes estimados e seus respectivos testes t, com a modelagem ARIMAX.

Formulação do modelo ARIMAX: $\phi(B)(1-B)dYt=\beta 0+\beta 1X1,t+\beta 2X2,t+\theta(B)\varepsilon$

A escolha desta modelagem para o PDD se fundamenta na crescente necessidade de ferramentas analíticas capazes de antecipar riscos de crédito de forma mais contextualizada e precisa. Em um país como o Brasil, com alta volatilidade econômica, prever inadimplência requer sensibilidade às mudanças no ambiente externo, como inflação e desemprego, que afetam diretamente a capacidade de pagamento das famílias.

Além disso, as metodologias tradicionais baseadas apenas em dados históricos de inadimplência interna muitas vezes subestimam ou superestimam os riscos quando confrontadas com cenários econômicos atípicos. A integração de variáveis exógenas nos modelos de previsão é, portanto, um avanço metodológico relevante para ampliar a eficácia da análise.

4.2 Coleta de dados e seleção da amostra

Os dados utilizados neste estudo são séries temporais mensais obtidas de fontes oficiais e confiáveis. A série de inadimplência é extraída a partir das "rolagens curtas" (atrasos iniciais) do pagamento do cartão de crédito. As variáveis macroeconômicas utilizadas são o Índice de Preços ao Consumidor Amplo (IPCA) e a Taxa de Desocupação

(desemprego), obtidas do Banco Central do Brasil e do IBGE, respectivamente. A base de dados será estruturada para garantir a coerência temporal e a compatibilidade entre as variáveis.

A amostra contempla o período de março de 2012 a dezembro de 2020, escolhido de forma a assegurar a disponibilidade simultânea das variáveis analisadas e evitar distorções causadas pelos choques macroeconômicos decorrentes da pandemia de COVID-19 a partir de 2020.

A variável dependente, taxa de inadimplência, foi extraída da série nº 21129 do Sistema Gerenciador de Séries Temporais (SGS) do Banco Central do Brasil (BCB), que corresponde inadimplência da carteira de crédito com recursos livres - pessoas físicas - cartão de crédito total. Essa série reflete o percentual de operações em atraso dentro do estoque de crédito, sendo uma medida amplamente utilizada no acompanhamento do risco de crédito bancário.

As variáveis explicativas (exógenas) utilizadas no modelo são indicadores macroeconômicos que influenciam a capacidade de pagamento dos consumidores:

- Índice de Preços ao Consumidor Amplo (IPCA) — série nº 433 do BCB, calculada pelo IBGE, que mensura a variação dos preços ao consumidor final e serve como indicador oficial da inflação brasileira;

- Taxa de Desocupação (Desemprego) — A variável de desemprego adotada neste trabalho foi obtida por meio do Banco Central do Brasil, sob o código **24369**, que disponibiliza a **Taxa de Desocupação – PNADC/IBGE (mensal)**. Essa série é construída a partir da Pesquisa Nacional por Amostra de Domicílios Contínua (PNADC), conduzida pelo Instituto Brasileiro de Geografia e Estatística (IBGE), e representa a proporção da força de trabalho que se encontra desocupada em relação ao total de indivíduos economicamente ativos. Essa medida é considerada o principal indicador do mercado de trabalho brasileiro, fornecendo uma visão abrangente da dinâmica de emprego e renda no país. Por apresentar frequência **mensal**, cobertura nacional e metodologia padronizada, a série é amplamente empregada em estudos macroeconômicos, previsões de ciclos econômicos e

modelos de risco de crédito. Sua disponibilidade contínua e consistência estatística tornam a série adequada para análises econômicas, incluindo modelos ARIMA e ARIMAX.

O corte temporal anterior à pandemia de 2020 justifica-se pela necessidade de excluir um período atípico de instabilidade econômica e sanitária que poderia comprometer a estacionariedade das séries e introduzir choques estruturais nos parâmetros do modelo. Dessa forma, a amostra selecionada representa um intervalo de relativa estabilidade macroeconômica, suficiente para capturar a dinâmica de longo prazo entre inadimplência, inflação e desemprego no Brasil.

4.3 Tratamento de dados

Após a coleta e consolidação das séries temporais conforme descrito acima, foi realizada uma etapa de tratamento e pré-processamento com o objetivo de garantir a comparabilidade, a consistência temporal e a adequação estatística dos dados para a modelagem econométrica proposta.

Inicialmente, todas as séries foram padronizadas para serem vistas em granularidade mensal, tomando como referência o primeiro dia de cada mês. Esse procedimento assegura que as observações de diferentes fontes apresentam sincronia temporal, fundamental para a estimação de modelos que incorporam variáveis exógenas.

A primeira série temporal observada e tratada foi a inadimplência, que é a série principal a ser observada nesse trabalho, e que pode ser visualizada na Figura 1.

Figura 1 - Inadimplência

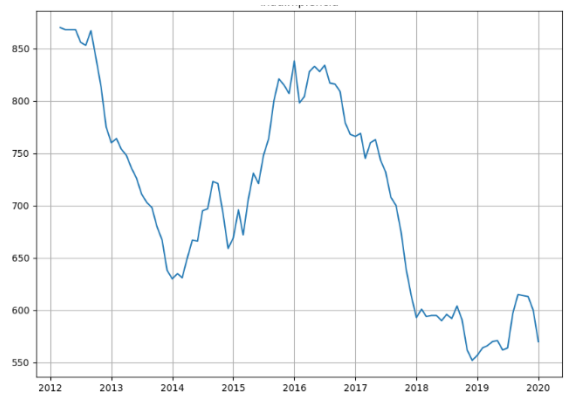

Figura 2 - Decomposição da Inadimplência

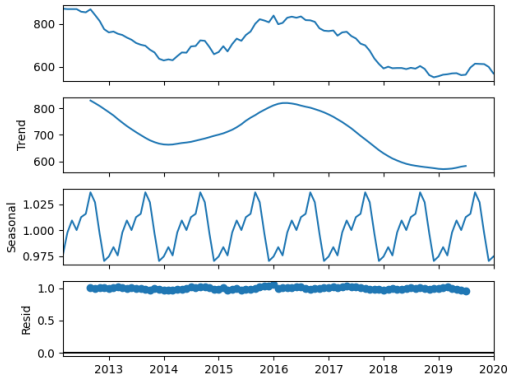

Ao observar a série decomposta em tendencia, sazonalidade e resíduos (Figura 2), observou-se que os resíduos iniciais estavam em torno de 1, e com isso, optou-se por realizar o tratamento inicial com logaritmo natural da taxa no momento t sobre a taxa no momento t-1, conseguindo assim a taxa da diferença.

Log: $Yt*=ln(Yt)$

Diferenciação: $\Delta Yt=Yt-Yt-1$

Após decompor a série com esse tratamento, observa-se uma adequação maior principalmente nos resíduos conforme a Figura 3.

Figura 3 - Decomposição da inadimplência tratada

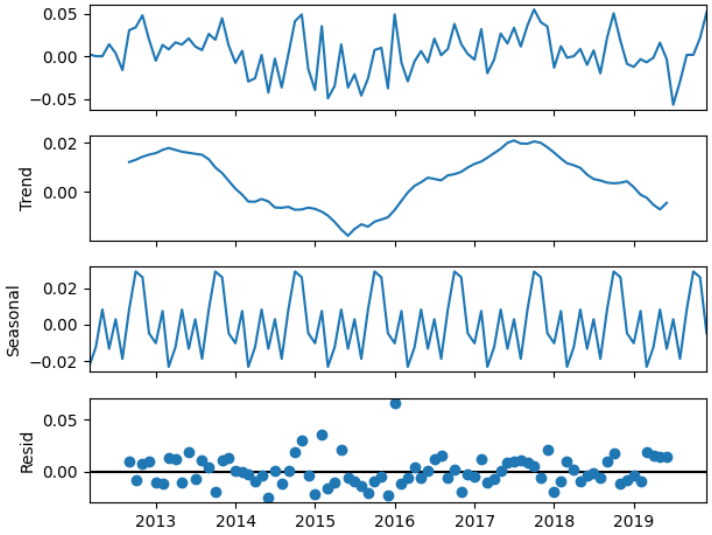

Posteriormente, foi realizado o teste de ADF, para realizar a estacionariedade da série após os tratamentos. O resultado foi um p-valor de 0,57, com um ADF de -1,41, que indica a não estacionariedade da variável. Com isso, foi realizada a dessazonalização da série para verificar se, ao retirar esse efeito, a estacionariedade seria alcançada, contudo o *seasonal_decompose* aplicado acabou por gerar um modelo inadequado, pois o efeito de sazonalidade na série na verdade não existe, mas sim é o próprio ciclo dos dados puros. Desse modo, optou-se apenas por diferenciar em primeira ordem os resultados do tratamento anterior e verificar o modelo ARIMA que melhor se adequa a ela.

ADF: $\Delta Yt=\alpha+\beta t+\gamma Yt-1+i=1\sum p\delta i\Delta Yt-i+\varepsilon t$

Após a realização do teste ADF na série diferenciada, observou-se então estacionariedade, com valores absolutamente aderentes (ADF: -6.30 e p-valor: 3.33e-08). Assim, o passo seguinte foi realizar um looping para descobrir qual é o modelo ARIMA com BIC, AIC e principalmente HQIC mais aderentes. Também foi fixado d = 0 já que a série que o modelo foi aplicado já era a série diferenciada (batizada de inad_sugerida_log_diff).

Durante a aplicação do ARIMA, a constante apresentou um resultado não significativo nos modelos, então foi removida. Após realizar a testagem de vários modelos com q e p diferentes, o escolhido foi o ARIMA(0,0,1). Ele apresentou um coeficiente MA(1) negativo e estatisticamente significativo (-0,825; p<0,01), indicando que choques aleatórios na inadimplência possuem caráter transitório e tendem a ser corrigidos no mês subsequente, reduzindo a persistência da série. Os testes diagnósticos demonstram que os resíduos são livres de autocorrelação (Ljung-Box, p=0,19), homocedásticos (ARCH-LM, p=0,48) e aproximadamente normais (Jarque-Bera, p=0,82), sugerindo adequação do modelo aos pressupostos de ruído branco. Dessa forma, o modelo se mostra estatisticamente consistente para previsão de curto prazo.

Para avaliar a presença de heterocedasticidade condicional (efeitos ARCH) nos resíduos do modelo ARIMA, foi aplicado o teste LM de Engle. Os resultados indicam que a hipótese nula de ausência de heterocedasticidade não pode ser rejeitada (LM = 14,27; p = 0,161). De forma consistente, o teste F também apresentou p-valor superior a 0,05 (F = 1,49; p = 0,159). Assim, conclui-se que os resíduos apresentam comportamento homocedástico, não havendo evidências de efeitos ARCH. Portanto, não é necessária a utilização de modelos complementares do tipo ARCH/GARCH para tratamento da variância condicional.

Para avaliar se o modelo ARIMA(0,0,1) havia capturado integralmente a estrutura temporal da série, estimou-se um Modelo Linear Generalizado (GLM) tendo os resíduos como variável dependente e uma tendência temporal como regressor. Os resultados indicam que o coeficiente associado ao tempo não é estatisticamente significativo (p-valor = 0,941), assim como o intercepto (p-valor = 0,984), revelando ausência de tendência ou padrão sistemático nos resíduos. O pseudo R^2 próximo de zero confirma que não há

variáveis capazes de explicar a variância residual. Dessa forma, conclui-se que os resíduos se comportam como ruído branco, validando a adequada especificação do modelo ARIMA e indicando que sua estrutura dinâmica foi plenamente capturada.

Adicionalmente, aplicou-se o teste de Kolmogorov–Smirnov (KS) como medida complementar para avaliar a aderência dos resíduos à distribuição normal. O teste apresentou estatística KS = 0,0602 e p-valor = 0,8679, não rejeitando a hipótese nula de normalidade ao nível de significância de 5%.

Esses resultados servem como base para a próxima etapa da análise, que consiste em verificar se a inclusão de variáveis macroeconômicas — por meio de um modelo ARIMAX — melhora a capacidade explicativa e preditiva da série.

A segunda etapa consistiu no tratamento das variáveis que seriam utilizadas como exógenas no modelo de modo que fiquem estacionárias.

O IPCA (Figura 4) foi a primeira variável tratada, utilizando a mesma regra aplicada a inadimplência: logaritmo natural da taxa no momento t sobre a taxa no momento t-1, conseguindo assim a taxa da diferença. Após isso, o teste de ADF foi aplicado e a série se mostrou estacionária com um p-valor de 0,0039 e um ADF de -4,33.

Figura 4 - IPCA

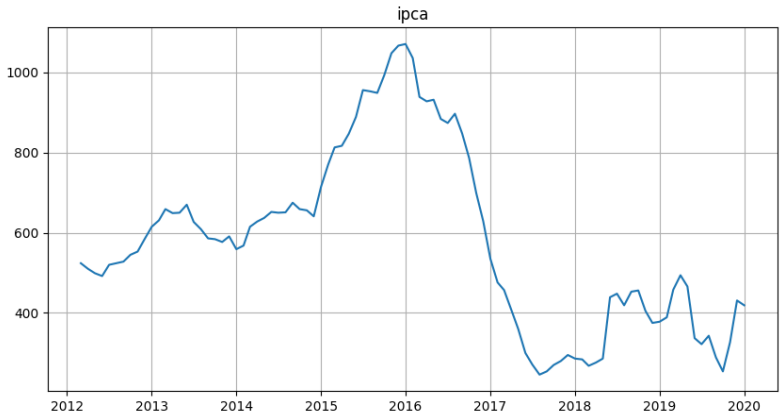

Após isso, a varável desemprego passa a ser tratada. Optou-se por utilizar a variável com inclusão de diversas defasagens como em cinco meses (Figura 5), pois assim se captura o

efeito defasado das condições do mercado de trabalho sobre a inadimplência, dado que a pessoa física normalmente usufruí de seguro-desemprego e FGTS.

Figura 5 – Desemprego em lag 5

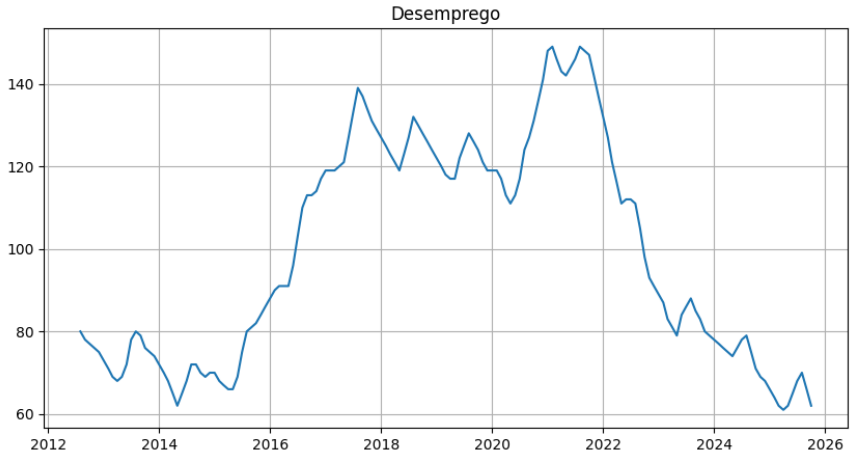

Também foi realizado o tratamento da variável com a defasagem de 1 mês (Figura 6), dado que no mês seguinte a um desligamento, o poder de pagamento daquela família já diminui. Como o impacto do desemprego sobre o não pagamento não ocorre de forma imediata, mas sim com atraso de alguns meses, o uso de defasagens da variável exógena é fundamental para uma modelagem realista da dinâmica de crédito

Figura 6 - Desemprego em lag 1

Ademais, a série também recebeu o tratamento para logaritmo natural da taxa no momento t sobre a taxa no momento t-1, conseguindo assim a taxa da diferença. Com esse

tratamento, a série com 5 meses de defasagem não se mostrou estacionária logo após o tratamento. Assim optou-se por diferenciar o encadeamento, e assim, o teste ADF apresentou resultado de -3,822 com p-valor 0,002, tonando-se estacionário. A série com 1 mês de descompasso seguiu o mesmo comportamento, mas na segunda diferença se mostrou estacionária com um ADF de -4,914 e um p-valor de 3,26e-05.

Assim, elas estão prontas para serem incorporadas no ARIMAX(0,0,1)

4.4 Apresentação e análise dos resultados

Com a estimação do modelo base da inadimplência ARIMA(0,0,1), as variáveis exógenas tratadas começaram a ser incorporadas no modelo.

Observou-se que o modelo ARIMA(0,0,1) sem variáveis exógenas apresentou ajuste estatisticamente superior ao modelo ARIMAX com o IPCA, com resíduos bem-comportados e ausência de autocorrelação. A inclusão do IPCA deteriorou a estrutura do modelo, tornando o termo MA(1) não significativo e introduzindo autocorrelação nos resíduos, o que indica especificação inadequada. Assim, apesar do coeficiente do IPCA ser estatisticamente significativo, sua inclusão não contribui para melhorar o ajuste global do modelo, sugerindo que a dinâmica da inadimplência é predominantemente explicada por sua própria estrutura temporal.

A inclusão da taxa de desemprego defasada em cinco períodos no modelo ARIMAX(0,0,1) não apresentou significância estatística ($p = 0,946$), indicando ausência de relação direta ou indireta entre essa variável macroeconômica e a variação da inadimplência após o controle pela dinâmica interna da série. Apesar disso, o modelo manteve excelente comportamento residual: não houve evidências de autocorrelação (Ljung–Box $p = 0,16$), de heteroscedasticidade ($p = 0,93$) ou de desvio de normalidade (Jarque–Bera $p = 0,73$). Assim, a variável de desemprego com defasagem de 5 meses não contribui para melhorar a capacidade explicativa do modelo, mas sua inclusão também não compromete a estrutura estatística, sinalizando que a inadimplência é predominantemente explicada pela sua própria componente temporal no período analisado.

Agora ao observar o modelo quando incorporada a taxa de desemprego defasada em um único período ao modelo ARIMAX(0,0,1), observou-se que o coeficiente associado à variável macroeconômica torna-se altamente significativo (coef = 0,2382; p = 0,005). Esse resultado evidencia que aumentos no desemprego estão diretamente relacionados ao aumento da inadimplência já no mês seguinte, reforçando a sensibilidade do comportamento de pagamento das famílias às condições do mercado de trabalho. O termo de média móvel (MA(1)) manteve-se significativo e elevado (coef = –0,8660; p < 0,001), indicando forte dependência da série a choques idiossincráticos de curto prazo. Os testes de diagnóstico confirmam a adequação da modelagem: não há autocorrelação remanescente nos resíduos (Ljung–Box p = 0,39), a normalidade não é rejeitada (Jarque–Bera p = 0,41) e não foram detectadas evidências de heteroscedasticidade (p = 0,79). Dessa forma, o modelo ARIMAX com desemprego defasado mostra-se estatisticamente consistente e apresenta relevância econômica, sugerindo que a deterioração do mercado de trabalho contribui de maneira significativa para explicar a evolução da inadimplência no período analisado.

Para verificar a presença de heterocedasticidade nos resíduos do modelo, aplicou-se o teste de Breusch–Pagan (LM). Os resultados obtidos (LM = 3,98; p = 0,948; F = 0,36; p = 0,958) não rejeitam a hipótese nula de homocedasticidade, indicando que a variância dos resíduos permanece constante ao longo do tempo. Dessa forma, não há evidências de heterocedasticidade, reforçando a adequação do modelo ARIMAX e dispensando a necessidade de modelagem adicional via GARCH.

Para avaliar a presença de estrutura remanescente não capturada pelo modelo ARIMAX, estimou-se um Modelo Linear Generalizado (GLM) tendo os resíduos como variável dependente e o tempo como regressor. Os resultados indicam ausência de significância tanto no intercepto (p = 0,687) quanto no coeficiente associado ao tempo (p = 0,673), evidenciando que não há tendência ou padrão sistemático nos resíduos. O pseudo R^2 praticamente nulo reforça essa interpretação, indicando que nenhuma variável adicional explica a variabilidade residual. Dessa forma, o comportamento dos resíduos é consistente com ruído branco, corroborando a adequação da especificação do modelo ARIMAX.

Como teste complementar de aderência à distribuição normal, aplicou-se o teste de Kolmogorov–Smirnov (KS) aos resíduos do modelo. O resultado (estatística KS = 0,0599; p-valor = 0,8753) não rejeita a hipótese nula de normalidade, indicando que a distribuição empírica dos resíduos é consistente com a distribuição normal teórica.

Por fim, a estimação do modelo ARIMAX(0,0,1) com as variáveis IPCA e desemprego defasado em um período revela que apenas o desemprego apresenta significância estatística (coef = 0,2215; p = 0,011), indicando que a deterioração do mercado de trabalho exerce impacto direto e relevante sobre a inadimplência. O IPCA, por outro lado, não demonstrou contribuição significativa (p = 0,834), sugerindo que a inflação não desempenha papel determinante na variação da inadimplência quando controladas a dinâmica temporal da série e as condições do mercado de trabalho. O termo MA(1) manteve-se altamente significativo ($p < 0,001$), reforçando a forte dependência da série em relação a choques de curto prazo. Os testes de diagnóstico validam a adequação do modelo, sem evidências de autocorrelação (Ljung–Box p = 0,23), heteroscedasticidade (p = 0,80) ou desvios de normalidade (Jarque–Bera p = 0,46). Dessa forma, o modelo evidencia que o desemprego é o principal determinante macroeconômico da inadimplência no período analisado.

O teste de Breusch–Pagan (LM) foi aplicado com o objetivo de avaliar a presença de heteroscedasticidade nos resíduos do modelo ARIMAX. Os resultados (LM = 4,2456; p = 0,9356; F = 0,3877; p = 0,9480) não rejeitam a hipótese nula de homocedasticidade, indicando que a variância dos resíduos é constante ao longo do tempo. Dessa forma, não há evidências de heteroscedasticidade, e a inclusão das variáveis macroeconômicas não gerou instabilidade na variância do erro. Esse achado reforça a adequação estatística do modelo e confirma que não há necessidade de ajustes adicionais via modelos ARCH/GARCH.

Para investigar a presença de estrutura remanescente nos resíduos do modelo ARIMAX, estimou-se um Modelo Linear Generalizado (GLM) utilizando o tempo como variável explicativa. Nenhum dos coeficientes apresentou significância estatística (constante: p = 0,516; tendência temporal: p = 0,377), indicando que não há tendência, padrão sistemático ou componente determinística não capturada pelo modelo. O pseudo R^2 praticamente nulo reforça a ausência de capacidade explicativa adicional. Esses resultados confirmam que os resíduos se

comportam como ruído branco, evidenciando a consistência e adequação da especificação ARIMAX adotada.

O teste de Kolmogorov–Smirnov (KS) foi aplicado como medida adicional de aderência dos resíduos à distribuição normal. O resultado obtido (estatística KS = 0,0619; p = 0,8509) não rejeita a hipótese nula de normalidade, indicando forte compatibilidade entre a distribuição empírica dos resíduos e a distribuição normal teórica.

5. Considerações finais

O presente trabalho teve como objetivo analisar a dinâmica da inadimplência ao longo do tempo e investigar em que medida variáveis macroeconômicas, como a taxa de desemprego e o IPCA, contribuem para explicar seu comportamento. Para isso, foram empregados modelos de séries temporais da família ARIMA e ARIMAX, amplamente utilizados na literatura de risco de crédito para capturar tanto a estrutura temporal da série quanto o impacto de fatores externos sobre sua evolução.

A comparação entre os três modelos apresentados — ARIMAX com **IPCA**, ARIMAX com **desemprego defasado em um e cinco meses**, e ARIMAX com **IPCA + desemprego** — permite identificar o comportamento das variáveis macroeconômicas quando incorporadas à modelagem da inadimplência.

No primeiro modelo, a inclusão do IPCA não trouxe ganho estatístico relevante: o coeficiente apresentou p-valor elevado e intervalo de confiança abrangendo zero, indicando ausência de significância econômica e estatística. Assim, a inflação mensal não demonstrou poder explicativo consistente sobre a inadimplência no período analisado, o que é coerente com a literatura que aponta que seus efeitos sobre o crédito tendem a ser indiretos e defasados.

O modelo que incorpora o desemprego defasado em cinco períodos não apresentou significância, porém em um período apresentou o melhor desempenho entre os três. O coeficiente foi estatisticamente significativo ao nível de 5%, indicando que variações no mercado de trabalho influenciam a inadimplência de forma direta e detectável pelo modelo. Apesar de o sinal negativo parecer contraintuitivo, ele indica possíveis efeitos institucionais, como restrição de crédito após períodos de deterioração do emprego ou maior rigor nas políticas internas de concessão. Os testes de diagnóstico também demonstraram resíduos bem-comportados, sem autocorrelação e com variância constante, reforçando a robustez do ajuste.

Por fim, o modelo que incorpora simultaneamente IPCA e desemprego não apresentou significância para nenhuma das variáveis exógenas. A perda de significância do desemprego quando o IPCA é incluído sugere possível multicolinearidade ou

sobreposição de efeitos macroeconômicos, reduzindo o poder individual de cada variável. Nesse caso, apesar dos resíduos permanecerem adequados, o modelo não oferece ganho explicativo em relação ao modelo apenas com desemprego.

Assim, o modelo mais consistente é o que inclui o desemprego defasado, que apresenta significância estatística, boa qualidade de ajuste e contribui para explicar a dinâmica da inadimplência. Já o IPCA, isolado ou combinado, não demonstrou impacto estatisticamente robusto na série.

Os resultados indicam que empresas devem priorizar o acompanhamento do desemprego como principal variável macroeconômica associada à inadimplência. Recomenda-se que instituições financeiras ajustem suas políticas de crédito em função de deteriorações no mercado de trabalho, revisem o timing de write-offs e incorporem cenários adversos de emprego em testes de estresse e modelos de PDD. A inflação, por sua vez, não demonstrou relevância explicativa no curto prazo, devendo ser utilizada apenas em análises estruturais ou modelos de longo prazo. A forte dependência autorregressiva da inadimplência reforça que modelos combinando memória temporal e condições do emprego produzem estimativas mais robustas e alinhadas às práticas prudenciais.

Como possibilidade de continuidade deste estudo, sugere-se o desenvolvimento de modelos que incluam um conjunto mais amplo de variáveis macroeconômicas, tais como taxa de juros real, nível de endividamento das famílias, massa salarial e indicadores de atividade econômica, permitindo avaliar se tais fatores ampliam a capacidade preditiva da inadimplência.

Além disso, recomenda-se a investigação de diferentes defasagens para o desemprego e para o IPCA, bem como a aplicação de técnicas de seleção de variáveis para mitigar potenciais problemas de multicolinearidade observados neste trabalho. Outra possibilidade relevante é a utilização de metodologias mais robustas, como modelos GARCH, VAR/VECM, modelos de sobrevivência ou algoritmos de machine learning, que podem capturar relações não lineares e efeitos de heterogeneidade não observados nos modelos ARIMA/ARIMAX.

Também se mostra promissora a construção de modelos individuais de Probabilidade de Default (PD), substituindo a inadimplência agregada por microdados de contratos, o que permitiria análises mais aderentes aos requisitos de Basileia e IFRS 9. Por fim, estudos futuros poderiam avaliar o impacto de eventos extraordinários, como crises sanitárias ou choques fiscais, sobre a dinâmica da inadimplência, estimando modelos estruturais capazes de mensurar rupturas de tendência e suas implicações na PDD das instituições financeiras.

Dessa maneira, o estudo contribui para compreensão macroprudencial do risco de crédito.

Referências

Allen, Franklin; Carletti, Elena; Marquez, Robert. **Credit market competition and capital regulation**. *The Review of Financial Studies*, Oxford, v. 24, n. 4, p. 983–1018, abr. 2011.

Altman, Edward I. **Financial ratios, discriminant analysis and the prediction of corporate bankruptcy**. *The Journal of Finance*, Hoboken, v. 23, n. 4, p. 589–609, set. 1968.

Banco Central do Brasil. **Resolução nº 4.193, de 1º de março de 2013**. Dispõe sobre a implementação de Basileia III no Brasil. Brasília: BCB, 2013.

Basel Committee on Banking Supervision. **International convergence of capital measurement and capital standards**. Basel: Bank for International Settlements, 1988.

Basel Committee on Banking Supervision. International convergence of capital measurement and capital standards: a revised framework. Basel: Bank for International Settlements, 2004.

Basel Committee on Banking Supervision. **Basel III: a global regulatory framework for more resilient banks and banking systems**. Basel: Bank for International Settlements, 2010.

Box, G. E. P.; Jenkins, G. M. **Time series analysis: forecasting and control**. San Francisco: Holden-Day, 1970.

Costa, Daniel; Almeida, José. **Machine learning aplicado ao risco de crédito: evidências no mercado brasileiro de cartões**. *Revista de Administração Contemporânea*, v. 24, n. 6, p. 753–771, 2020.

Engle, Robert F. Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, v. 50, n. 4, p. 987–1007, 1982.

Ipea – Instituto de Pesquisa Econômica Aplicada. **Macroeconomia para o desenvolvimento: emprego e inflação no Brasil**. Brasília: Ipea, 2022.

Jackson, P.; Pera, A. **Regulating and supervising in a changing financial world**. Basel: Bank for International Settlements, 1999. (Working papers, n. 62).

Lakatos, Eva Maria; Marconi, Marina de Andrade. Metodologia do trabalho científico: procedimentos básicos, pesquisa bibliográfica, projeto e relatório, publicações e trabalhos científicos. 6. ed. São Paulo: Atlas, 2003.

Lanzana, A. E. T. **Economia brasileira: fundamentos e atualidade**. 5. ed. São Paulo: Atlas, 2017.

Mankiw, N. Gregory. **Macroeconomia**. 10. ed. Rio de Janeiro: LTC, 2019.

Marçal, Emerson Fernandes; Pereira, Pedro Luiz Valls. **Indicadores macroeconômicos explicam e preveem a inadimplência? Um estudo dos dados brasileiros**. *Revista Brasileira de Economia*, Rio de Janeiro, v. 74, n. 4, p. 385–407, out./dez. 2020.

Morettin, Pedro A.; Toloi, Clélia M. C. **Análise de séries temporais**. 2. ed. São Paulo: Edgard Blücher, 2006.

Repullo, Rafael; Suarez, Javier. **The procyclical effects of bank capital regulation**. *Review of Financial Studies*, v. 26, n. 2, p. 452–490, 2013.

Saunders, Anthony; Allen, Linda. **Credit risk measurement: new approaches to value at risk and other paradigms**. 2. ed. New York: John Wiley & Sons, 2002.

Silva, Carlos; Mattos, Felipe. Modelos de risco de crédito e fatores macroeconômicos: uma análise aplicada ao Brasil. *Revista Brasileira de Finanças*, v. 19, n. 1, 2021.

Apêndice

```
!pip install ipeadatapy

import pandas as pd

import numpy as np

import itertools

import requests

from statsmodels.api import OLS, add_constant

from statsmodels.tsa.stattools import adfuller

import matplotlib.pyplot as plt

from statsmodels.graphics.tsaplots import plot_acf, plot_pacf

from statsmodels.tsa.arima.model import ARIMA

from statsmodels.stats.diagnostic import acorr_ljungbox

from statsmodels.tsa.statespace.sarimax import SARIMAX

from statsmodels.tsa.seasonal import seasonal_decompose

import ipeadatapy as ipea

from statsmodels.tsa.seasonal import STL

from statsmodels.graphics.gofplots import qqplot

import matplotlib.pyplot as plt

import statsmodels.api as sm

from statsmodels.stats.diagnostic import het_arch

import statsmodels.stats.api as sms

from scipy.stats import shapiro

import seaborn as sns

from scipy.stats import kstest, norm

 def load_bcb_series(code: int, colname: str) -> pd.DataFrame:

    url = f"https://api.bcb.gov.br/dados/serie/bcdata.sgs.{code}/dados?formato=json"
```

```
    js = requests.get(url, timeout=30).json()
    df = pd.DataFrame(js).rename(columns={"data": "date", "valor": colname})
    df["date"] = pd.to_datetime(df["date"], format="%d/%m/%Y", errors="coerce")
    df[colname] = (pd.Series(df[colname].astype(str))
                   .str.replace(".", "", regex=False)
                   .str.replace(",", ".", regex=False)
                   .astype(float))
    return df.set_index("date").sort_index()
  def prep_monthly(df: pd.DataFrame, col: str) -> pd.DataFrame:
    start = df.index.min().to_period("M").to_timestamp()
    end   = df.index.max().to_period("M").to_timestamp()
    idx = pd.date_range(start, end, freq="MS")
    out = df.reindex(idx)
    out[col] = out[col].ffill()
    return out
# Baixar séries
df_inad = load_bcb_series(21129, "inadimplencia") # Inadimplência cartão
df_ipca = load_bcb_series(13522,   "ipca")         # IPCA var% mensal
df_desemprego  = load_bcb_series(24369, "desemprego")  # PNAD Contínua (IBGE)
# Padronizar calendário mensal contínuo
df_inad = prep_monthly(df_inad, "inadimplencia")
df_ipca = prep_monthly(df_ipca, "ipca")
df_desemprego  = prep_monthly(df_desemprego,  "desemprego")
ipca = df_ipca.loc['2012-03-01':'2020-01-01']
inad = df_inad.loc['2012-03-01':'2020-01-01']
desemprego = df_desemprego.loc['2012-03-01':]
```

```
#PLOTANDO O GRAFICO
plt.figure(figsize = (10,7))
plt.title('Inadimplencia')
plt.plot(inad.index,inad['inadimplencia'])
plt.grid(True)
#decomposição da sazonalidade
decomp_12 = seasonal_decompose(inad.dropna(), model='multiplicative', period=12)
decomp_12.plot()
#gráfico com tratamento da variável
inad_sugerida_log = np.log(inad/inad.shift(-1))
inad_sugerida_log.dropna()
decomp = seasonal_decompose(inad_sugerida_log.dropna(), model='adictive', period=12)
decomp.plot()
resultado = adfuller(inad_sugerida_log.dropna())
print("ADF:", resultado[0])
print("p-valor:", resultado[1])
inad_sugerida_log_diff = inad_sugerida_log.diff().dropna()
resultado = adfuller(inad_sugerida_log_diff.dropna())
print("ADF:", resultado[0])
print("p-valor:", resultado[1])
#ARIMA COM LOG
p_values = range(0, 6)
d_values = [0]
q_values = range(0, 6)
resultados = []
serie = inad_sugerida_log_diff.dropna()   # garante limpeza
```

```
for p, d, q in itertools.product(p_values, d_values, q_values):
    ordem = (p, d, q)
    try:
        modelo = ARIMA(
            serie,
            order=ordem,
            trend='n'
        ).fit()
        resultados.append([
            f'ARIMA{ordem}',
            p, d, q,
            modelo.aic,
            modelo.bic,
            modelo.hqic
        ])
    except Exception as e:
        # print(f"Erro no ARIMA{ordem}: {e}")
        pass
df = pd.DataFrame(resultados, columns=['Modelo','p','d','q','AIC','BIC','HQIC'])
print(df.sort_values(by='HQIC').head(10))
modelo_101 = ARIMA(inad_sugerida_log_diff, order=(1,0,1), trend='n').fit()
print("\nARIMA(1,0,1)")
print(modelo_101.summary())
modelo_002 = ARIMA(inad_sugerida_log_diff, order=(0,0,2),trend='n').fit()
print("\nARIMA(0,0,2)")
print(modelo_002.summary())
```

```
modelo_001 = ARIMA(inad_sugerida_log_diff, order=(0,0,1), trend='n').fit()
print("\nARIMA(0,0,1)")
print(modelo_001.summary())
lm_test = het_arch(modelo_001.resid)
print(f"LM stat: {lm_test[0]}")
print(f"LM p-value: {lm_test[1]}")
print(f"F stat: {lm_test[2]}")
print(f"F p-value: {lm_test[3]}")
# resíduos do modelo ARIMA puro
resid = modelo_001.resid   # ajuste o nome do seu modelo
df_glm = pd.DataFrame({
    'resid': resid
})
# criar um "tempo" para testar tendência
df_glm['tempo'] = range(len(df_glm))
df_glm = df_glm.dropna()
# X = apenas tempo
X = df_glm[['tempo']]
X = sm.add_constant(X)
y = df_glm['resid']
glm_model = sm.GLM(y, X, family=sm.families.Gaussian())
glm_results = glm_model.fit()
print(glm_results.summary())
# padronizando os resíduos
resid_std = (resid - resid.mean()) / resid.std()
# teste KS contra uma normal padrão
```

```
ks_stat, ks_pvalue = kstest(resid_std, 'norm')

print(ks_stat, ks_pvalue)

#tratamento dataframe

inad_sugerida_log_diff = inad_sugerida_log_diff.reset_index()

inad_sugerida_log_diff.columns = ['data', 'inadimplencia']

inad_sugerida_log_diff.dropna()

#PLOTANDO O GRAFICO

plt.figure(figsize = (10,5))

plt.title('ipca')

plt.plot(ipca.index,ipca['ipca'])

plt.grid(True)

#gráfico com tratamento da variável

ipca_sugerida_log = np.log(ipca/ipca.shift(-1))

ipca_sugerida_log.dropna()

decomp_ipca = seasonal_decompose(ipca_sugerida_log.dropna(), model='adictive',
period=12)

decomp_ipca.plot()

resultado_ipca = adfuller(ipca_sugerida_log.dropna())

print("ADF:", resultado_ipca[0])

if resultado_ipca[1] > 0.05:

   print("Não estacionária, P-valor:", resultado_ipca[1])

else:

   print("Estacionária, P-valor:", resultado_ipca[1])

#tratamento dataframe sazonalidade

sazonalidade_ipca = decomp_ipca.seasonal.reset_index()

sazonalidade_ipca.columns = ['data', 'valor']
```

```
sazonalidade_ipca.dropna()

#tratamento dataframe trend

trend_ipca = decomp_ipca.trend.reset_index()

trend_ipca.columns = ['data', 'valor']

trend_ipca.dropna()

#tratamento dataframe resi

residuos_ipca = decomp_ipca.resid.reset_index()

residuos_ipca.columns = ['data', 'valor']

residuos_ipca.dropna()

#tratamento dataframe

ipca_sugerida_log = ipca_sugerida_log.reset_index()

ipca_sugerida_log.columns = ['data', 'ipca']

ipca_sugerida_log.dropna()

#trata lag

desemprego_1 = desemprego[['desemprego']].copy()

desemprego_1['desemprego_lag1'] = desemprego['desemprego'].shift(1)

desemprego_1 = desemprego_1.dropna()

#trata serie

desemprego_sugerida_log_lag1 =
np.log(desemprego_1['desemprego_lag1']/desemprego_1['desemprego_lag1'].shift(-1))

desemprego_sugerida_log_lag1.dropna()

decomp_desemprego = seasonal_decompose(desemprego_sugerida_log_lag1.dropna(),
model='adictive', period=12)

decomp_desemprego.plot()

#PLOTANDO O GRAFICO

plt.figure(figsize = (10,5))

plt.title('Desemprego')
```

```
plt.plot(desemprego_1.index,desemprego_1['desemprego_lag1'])
plt.grid(True)
resultado_desemprego_lag1 = adfuller(desemprego_sugerida_log_lag1.dropna())
print("ADF:", resultado_desemprego_lag1[0])
if resultado_desemprego_lag1[1] > 0.05:
   print("Não estacionária, P-valor:", resultado_desemprego_lag1[1])
else:
   print("Estacionária, P-valor:", resultado_desemprego_lag1[1])
desemprego_log_diff_lag1 = desemprego_sugerida_log_lag1.diff().dropna()
resultado_desemprego_lag1_diff = adfuller(desemprego_log_diff_lag1.dropna())
print("ADF:", resultado_desemprego_lag1_diff[0])
if resultado_desemprego_lag1_diff[1] > 0.05:
   print("Não estacionária, P-valor:", resultado_desemprego_lag1_diff[1])
else:
   print("Estacionária, P-valor:", resultado_desemprego_lag1_diff[1])
inad_sugerida_log_diff = inad_sugerida_log_diff.set_index('data')
ipca_sugerida_log     = ipca_sugerida_log.set_index('data')
dados_modelo_ipca = pd.concat([inad_sugerida_log_diff, ipca_sugerida_log], axis=1)
dados_modelo_ipca.columns = ['inad', 'ipca']
dados_modelo_ipca = dados_modelo_ipca.dropna()
X = dados_modelo_ipca[['ipca']]
y = dados_modelo_ipca['inad']
modelo_arimax_ipca = ARIMA(y, order=(0,0,1), exog=X).fit()
print(modelo_arimax_ipca.summary())
dados_modelo_desemprego_1 = pd.concat([inad_sugerida_log_diff,
desemprego_log_diff_lag1], axis=1)
```

```
dados_modelo_desemprego_1.columns = ['inad', 'desemprego_lag1']

dados_modelo_desemprego_1 = dados_modelo_desemprego_1.dropna()

X1 = dados_modelo_desemprego_1[['desemprego_lag1']]

y1 = dados_modelo_desemprego_1['inad']

modelo_arimax_desemprego_lag1 = ARIMA(y1, order=(0,0,1), exog=X1,trend='n').fit()

print(modelo_arimax_desemprego_lag1.summary())

lm_test_desemprego = het_arch(modelo_arimax_desemprego_lag1.resid)

print(f"LM stat: {lm_test_desemprego[0]}")

print(f"LM p-value: {lm_test_desemprego[1]}")

print(f"F stat: {lm_test_desemprego[2]}")

print(f"F p-value: {lm_test_desemprego[3]}")

# resíduos do modelo ARIMA puro

resid_desemprego = modelo_arimax_desemprego_lag1.resid   # ajuste o nome do seu
modelo


df_glm = pd.DataFrame({

   'resid': resid_desemprego

})

# criar um "tempo" para testar tendência

df_glm['tempo'] = range(len(df_glm))

df_glm = df_glm.dropna()

# X = apenas tempo

X2 = df_glm[['tempo']]

X2 = sm.add_constant(X2)

y2 = df_glm['resid']

glm_model = sm.GLM(y2, X2, family=sm.families.Gaussian())
```

```
glm_results = glm_model.fit()

print(glm_results.summary())

# padronizando os resíduos

resid_std_desemprego = (resid_desemprego - resid_desemprego.mean()) /
resid_desemprego.std()

# teste KS contra uma normal padrão

ks_stat, ks_pvalue = kstest(resid_std_desemprego, 'norm')

print(ks_stat, ks_pvalue)

desemprego_log_diff_lag1.columns = ['desemprego_lag1']

ipca_sugerida_log.columns = ['ipca']

dados_final = pd.concat([inad_sugerida_log_diff, desemprego_log_diff_lag1,
ipca_sugerida_log], axis=1)

dados_final.columns = ['inad', 'desemprego_lag1', 'ipca']

dados_final = dados_final.dropna()

X3 = dados_final[['desemprego_lag1', 'ipca']]

y3 = dados_final['inad']

modelo_arimax_vf = ARIMA(y3, order=(0,0,1), exog=X3, trend='n').fit()

print(modelo_arimax_vf.summary())

lm_test_final = het_arch(modelo_arimax_vf.resid)

print(f"LM stat: {lm_test_final[0]}")

print(f"LM p-value: {lm_test_final[1]}")

print(f"F stat: {lm_test_final[2]}")

print(f"F p-value: {lm_test_final[3]}")

# resíduos do modelo ARIMA puro

resid_final = modelo_arimax_vf.resid   # ajuste o nome do seu modelo

df_glm = pd.DataFrame({

    'resid': resid_final
```

```
})
# criar um "tempo" para testar tendência
df_glm['tempo'] = range(len(df_glm))
df_glm = df_glm.dropna()
# X = apenas tempo
X4 = df_glm[['tempo']]
X4 = sm.add_constant(X4)
y4 = df_glm['resid']
glm_model = sm.GLM(y4, X4, family=sm.families.Gaussian())
glm_results = glm_model.fit()
print(glm_results.summary())
# padronizando os resíduos
resid_std_final = (resid_final - resid_final.mean()) / resid_final.std()
# teste KS contra uma normal padrão
ks_stat, ks_pvalue = kstest(resid_std_final, 'norm')
print(ks_stat, ks_pvalue)
```